Logística de última milla en redes viales reales: un enfoque reproducible para el MDRP en La Paz, B.C.S.

Alan José Marcos Sánchez Martínez

Instituto Tecnológico de La Paz, Tecnológico Nacional de México (TecNM)

alansama2906@gmail.com

Resumen

La logística de última milla concentra entre el 30 % y el 60 % del costo de una operación de entrega y, en el segmento de comida preparada, se agrava por la urgencia y la demanda dinámica. La mayoría de los estudios sobre el *Meal Delivery Routing Problem* (MDRP) evalúan sus políticas de despacho con distancias euclidianas, que subestiman los trayectos reales entre un 17 % y un 40 % y comprometen la validez de los tiempos de entrega prometidos. Este trabajo evalúa la eficiencia operativa de la política anticipatoria de horizonte rodante (*Rolling Horizon*, RH) frente a una política reactiva *First-Come, First-Served* (FCFS) para el MDRP sobre la red vial real de La Paz, Baja California Sur. Se desarrolló un entorno de simulación de eventos discretos reproducible, basado exclusivamente en software libre (OSRM, OpenStreetMap y Docker), que sustituye las distancias euclidianas por tiempos de viaje reales. La demanda se generó mediante un proceso de Poisson no homogéneo bimodal calibrado con el conjunto de datos LaDe (aproximadamente 1 038 pedidos y 25 restaurantes) y ambas políticas se compararon en cuatro escenarios de saturación de flota con siete réplicas válidas, contrastadas con la prueba de Mann-Whitney U. Los resultados revelan dos regímenes: con flota holgada FCFS es más rápida, pero bajo saturación media y alta RH reduce el *Click-to-Door* promedio hasta un 57.2 % y su percentil 90 hasta un 77.1 %, además de eliminar los pedidos no entregados. Se identifica un punto de cruce entre 26 y 35 pedidos por repartidor a partir del cual la anticipación

supera a la asignación reactiva.

Palabras clave: MDRP; horizonte rodante; ruteo dinámico de vehículos; logística de última milla; OSRM; simulación de eventos discretos; software libre.

1. Introducción

La entrega de última milla —el segmento final desde el punto de origen hasta el domicilio del cliente— es el componente más costoso y complejo de la logística urbana: puede representar entre el 30 % y el 60 % del costo total de un envío (Jazemi, Alidadiani, Ahn, y Jang, 2023). En el caso de la comida preparada, este segmento se vuelve particularmente exigente por la urgencia (ventanas de 30 a 60 minutos), la perecibilidad del producto y una demanda dinámica e impredecible que obliga a reoptimizar continuamente las asignaciones.

El problema de enrutamiento de vehículos (VRP), formulado originalmente por Dantzig y Ramser (1959) como generalización del problema del agente viajero, ha evolucionado durante cinco décadas para incorporar restricciones de capacidad, ventanas de tiempo y múltiples depósitos (Laporte, 2009). Cuando la demanda se revela en tiempo real, el problema se torna dinámico (Larsen, 2000; Pillac, Gendreau, Guéret, y Medaglia, 2013). En esta familia, Reyes, Erera, Savelsbergh, Sahasrabudhe, y O'Neil (2018) introdujeron el *Meal Delivery Routing Problem* (MDRP), que combina múltiples puntos de recolección, tiempos de preparación, alta urgencia y agrupamiento dinámico de pedidos (*bundling*).

Un problema transversal a esta literatura es la manera de estimar los tiempos de viaje. Las plataformas comerciales (Google Maps, Mapbox) ofrecen precisión pero imponen costos de licenciamiento y operan como caja negra, comprometiendo la reproducibilidad científica (Pereira, Saraiva, Herszenhut, Braga, y Conway, 2021). La alternativa académica tradicional —la distancia euclidiana— es gratuita y reproducible, pero Boyacı, Dang, y Letchford (2021) demostraron, sobre 96 instancias en 12 ciudades, que las rutas reales son entre un 17 % y un 40 % más largas que la línea recta, lo que invalida las estimaciones de tiempo de arribo y puede producir rutas operativamente infactibles.

Esta brecha se agudiza en ciudades medianas de topología irregular como La Paz, Baja California Sur, donde la ensenada obliga a rodeos extensos y la estructura vial depende de pocas arterias

estructurantes. Además, Reyes y cols. (2018) validaron sus políticas de horizonte rodante en instancias sintéticas de grandes urbes con alta conectividad y distancias euclidianas; se desconoce el grado de degradación de estas heurísticas al trasladarlas a un entorno de baja conectividad y alta penalización por error.

De lo anterior surge la pregunta de investigación: *¿en qué medida una política de despacho anticipatoria supera a una reactiva cuando el MDRP se evalúa sobre la red vial real de una ciudad mediana de topología hostil?* El **objetivo general** es evaluar la eficiencia operativa de la política *Rolling Horizon* frente a la estrategia reactiva FCFS mediante un entorno de simulación reproducible que integre las restricciones topológicas reales de La Paz y patrones de demanda estocásticos. La **hipótesis** sostiene que la política anticipatoria, alimentada con tiempos de viaje reales, superará significativamente a la reactiva en eficiencia operativa y nivel de servicio, usando exclusivamente software de código abierto.

El resto del documento se organiza como sigue. La Sección 2 presenta el marco teórico (formulación del MDRP, heurística de horizonte rodante, enrutamiento sobre grafos viales y generación estocástica de demanda). La Sección 3 describe la metodología y el diseño experimental. La Sección 4 presenta y discute los resultados. La Sección 5 concluye y plantea líneas de trabajo futuro.

2. Marco teórico

2.1. Formulación del MDRP

El MDRP (Reyes y cols., 2018) se define sobre tres conjuntos: restaurantes $\mathscr{R}$ (con ubicación fija), órdenes $\mathscr{O}$ y repartidores (*couriers*) $\mathscr{C}$. Cada orden o se caracteriza por su restaurante de origen r_o, su instante de colocación a_o, su instante de disponibilidad o *ready time* $e_o \geq a_o$ y su ubicación de entrega ℓ_o; la información de la orden se revela al sistema únicamente en a_o (llegada dinámica). Toda la información de restaurantes y couriers se conoce a priori. El problema consiste en determinar rutas factibles que completen la recolección y entrega de las órdenes optimizando una o varias métricas de desempeño.

Dos suposiciones estructurales son centrales. Primero, el **agrupamiento** (*bundling*): órdenes de un mismo restaurante pueden combinarse en una ruta con múltiples entregas, cuyo *ready time*

es el máximo de sus órdenes constituyentes. Segundo, la **restricción de *ready time***: un courier no puede recoger una orden antes de que la comida esté lista. La remuneración sigue un esquema de compensación mínima garantizada:

$$\text{Pago}(c) = \max(p_1 n_c,\ p_2 (l_c - e_c)), \tag{1}$$

donde n_c es el número de órdenes entregadas por el courier c, $l_c - e_c$ la duración de su turno, p_1 el pago por orden y p_2 el pago mínimo por hora.

Las métricas primarias relevantes son el ***Click-to-Door*** (CtD, tiempo entre colocación y entrega, $\text{CtD}_o = t_{delivery,o} - a_o$), el ***Ready-to-Pickup*** (RtP, espera de la comida lista) y el ***Ready-to-Door*** (RtD), además de la utilización del courier y el costo por orden. El MDRP pertenece a los problemas dinámicos de recolección y entrega (Pillac y cols., 2013) y se distingue por combinar múltiples puntos de recolección, alta urgencia ($\tau \approx 40$ min) y dinamismo total, lo que descarta los métodos exactos y favorece heurísticas basadas en horizontes rodantes.

2.2. Heurística de horizonte rodante

El algoritmo de Reyes y cols. (2018) ejecuta, cada f minutos, un ciclo de agrupamiento, asignación y compromiso sobre las órdenes cuyo *ready time* cae dentro de un horizonte de asignación Δ_u. Para equilibrar la utilización de la flota con la frescura de las entregas, el **tamaño objetivo de agrupamiento** al instante t se define como la razón entre las órdenes próximas a estar listas y los couriers próximos a estar disponibles:

$$Z_t = \frac{|\{o \in \mathcal{O}_t : e_o \le t + \Delta_1\}|}{|\{c \in \mathcal{D}_t : e_c^{avail} \le t + \Delta_2\}|}, \qquad \Delta_1, \Delta_2 > 0, \tag{2}$$

donde $\mathcal{D}_t$ es el conjunto de couriers en turno. Cuando $Z_t < 1$ hay más couriers que órdenes y el comportamiento converge a asignaciones individuales; cuando $Z_t \gg 1$ el sistema está saturado y se favorecen agrupamientos mayores.

Determinado Z_t, se construyen agrupamientos por restaurante mediante inserción paralela con mejora local (*remove-reinsert*), y se clasifican en tres grupos de prioridad según su urgencia respecto al objetivo CtD τ. La asignación se resuelve secuencialmente por grupo como un **problema de asignación lineal**: para cada par agrupamiento-courier (s,d) se define el peso

$$w_{s,d} = \frac{N_s}{\max_{o \in s}\{\delta^s_{o,d}\} - e_d} - \theta\left(\pi_{s,d} - \max_{o \in s}\{e_o\}\right), \tag{3}$$

donde N_s es el número de órdenes del agrupamiento, $\delta^s_{o,d}$ el tiempo de entrega de la orden o, e_d el momento en que el courier d queda disponible, $\pi_{s,d}$ el tiempo de recolección y $\theta > 0$ penaliza el retraso respecto al *ready time*. El primer término premia la eficiencia (órdenes por unidad de tiempo) y el segundo la frescura. El problema se resuelve en $O(n^3)$ con el algoritmo húngaro (Kuhn, 1955).

Finalmente, una estrategia de **compromiso aditivo en dos etapas** (Reyes y cols., 2018) distingue entre compromiso final (el courier recoge y entrega en la época actual) y compromiso parcial o *inbound* (el courier se desplaza hacia el restaurante y su agrupamiento se confirma en la siguiente época). El compromiso parcial actúa como preposicionamiento y conserva flexibilidad ante nueva información.

2.3. Enrutamiento sobre grafos viales

Para eliminar el error de la aproximación euclidiana, este trabajo sustituye las distancias en línea recta por consultas sobre el grafo vial real mediante la cadena OpenStreetMap $\rightarrow$ OSRM. OpenStreetMap (OSM) modela la infraestructura mediante nodos, vías y relaciones (Boeing, 2021; Haklay, 2010), de las que se deriva un grafo $G = (V, E, c)$ con costos definidos por la distancia y la velocidad permitida de cada segmento.

El cálculo de caminos mínimos se acelera con *Contraction Hierarchies* (CH) (Geisberger, Sanders, Schultes, y Delling, 2008), técnica de preprocesamiento que contrae los nodos por orden de importancia e inserta aristas de atajo, permitiendo resolver consultas mediante búsqueda bidireccional en milisegundos. **OSRM** (*Open Source Routing Machine*) implementa CH sobre datos OSM en tres etapas (`osrm-extract`, `osrm-contract` y `osrm-routed`), con tiempos de respuesta típicos inferiores a 5 ms para grafos regionales. La sustitución de la distancia euclidiana por tiempos OSRM tiene tres consecuencias: los tiempos dejan de ser simétricos ($T(a,b) \neq T(b,a)$) por los sentidos de circulación, la desigualdad triangular se cumple de forma natural sobre la red y se elimina el factor de conversión euclidiano de Reyes y cols. (2018).

2.4. Generación estocástica de demanda

Las llegadas de pedidos se modelan mediante un **proceso de Poisson no homogéneo** (Ross, 2014), en el que el número de eventos en un intervalo sigue una distribución de Poisson cuyo parámetro es la integral de una función de intensidad $\lambda(t)$. Los servicios de comida exhiben dos picos diarios (almuerzo y cena) (Wu y cols., 2023), por lo que la intensidad se representa como la superposición de una base constante y dos componentes gaussianas:

$$\lambda(t) = \lambda_0 + A_m \exp\left(-\frac{(t-\mu_m)^2}{2\sigma^2}\right) + A_e \exp\left(-\frac{(t-\mu_e)^2}{2\sigma^2}\right), \tag{4}$$

con base λ_0, centros μ_m, μ_e, amplitudes A_m, A_e y dispersión σ. La propiedad de discretización de Poisson permite generar instancias mediante un simple muestreo minuto a minuto. Las métricas de desempeño se agregan con la media y los percentiles 50, 90 y 95; el percentil 90 es especialmente relevante porque captura la experiencia de los clientes en la cola de la distribución.

3. Metodología

3.1. Arquitectura del sistema

El entorno de simulación se organiza en tres capas funcionales desacopladas: (1) una capa de **enrutamiento** basada en OSRM v5.27.1 desplegado en un contenedor Docker (Merkel, 2014) que opera sobre `localhost` con el algoritmo CH sobre el extracto OSM de La Paz; (2) una capa de **simulación** de eventos discretos implementada en Python, que consulta tiempos y rutas al servidor OSRM vía HTTP; y (3) una capa de **análisis** que calcula los indicadores y genera las tablas y figuras. La contenerización garantiza que el entorno de cálculo sea idéntico en cualquier máquina anfitriona, y la operación *offline* elimina el consumo de APIs comerciales y las barreras económicas para la replicación.

3.2. Generación de instancias sintéticas

Cada instancia contiene aproximadamente 1 038 pedidos distribuidos en una ventana operativa diaria y asociados a 25 restaurantes. Los instantes de colocación se muestrean del proceso de Poisson no homogéneo bimodal de la Ecuación (4), calibrado con los picos de demanda del conjunto

de datos LaDe (Wu y cols., 2023). Las ubicaciones de restaurantes y clientes se muestrean dentro del polígono urbano de La Paz, validando que cada punto obtenga respuesta del servicio de enrutamiento. Los tiempos de preparación se modelan como $T_{prep} \sim \text{máx}(5, \mathcal{N}(12, 3^2))$ min. El tamaño de flota se dimensiona automáticamente según

$$|\mathscr{C}| = \text{máx}(n_{\text{mín}},\ \lceil |\mathscr{O}|/r \rceil)\,, \tag{5}$$

donde r es el número objetivo de pedidos por repartidor y $n_{\text{mín}} = 10$. El uso de semillas aleatorias garantiza la reproducibilidad exacta de las instancias.

3.3. Motor de simulación y políticas de despacho

La simulación avanza en **épocas de reoptimización** de $f = 5$ min. En cada época, cada orden transita por una máquina de estados (colocada $\rightarrow$ lista $\rightarrow$ asignada $\rightarrow$ recogida $\rightarrow$ entregada) y los tiempos de viaje se obtienen de OSRM. Se comparan dos políticas:

- **FCFS (línea base):** asignación reactiva e inmediata de cada pedido al courier disponible más cercano al restaurante, sin consolidación de órdenes.
- **Rolling Horizon (RH):** implementación de la heurística de la Sección 2.2, con cálculo del tamaño objetivo de agrupamiento (Ecuación 2), generación de agrupamientos por restaurante, clasificación por prioridad, asignación lineal (Ecuación 3) resuelta con el algoritmo húngaro (Kuhn, 1955) y compromiso en dos etapas.

Los parámetros del algoritmo se mantienen constantes: frecuencia de optimización $f = 5$ min, horizonte $\Delta_u = 20$ min, objetivo SLA $\tau = 40$ min, tiempo de servicio $s = 4$ min y tamaño máximo de agrupamiento $B_{max} = 4$. La compensación usa $p_1 = \$10$ por pedido y un piso de $p_2 = \$15$ por hora.

3.4. Diseño experimental

La variable de tratamiento es la **razón de saturación** r (pedidos por repartidor), que dimensiona la flota mediante la Ecuación (5) manteniendo fijo el volumen de pedidos. Se definen cuatro escenarios que cubren desde operación holgada hasta saturación alta (Tabla 1).

Tabla 1: Escenarios experimentales de saturación de flota ($|\mathscr{O}| \approx 1\,038$ pedidos). Fuente: elaboración propia.

Escenario	Nivel	r	$\lvert\mathscr{C}\rvert$	Descripción
S1	Baja	18	58	Línea base; capacidad holgada
S2	Moderada	26	40	Reducción moderada de flota
S3	Media	35	30	Punto medio de saturación
S4	Alta	52	20	Carga elevada por repartidor

Para cada combinación de escenario y semilla, ambas políticas se ejecutan sobre la *misma* instancia de pedidos y flota (comparación **pareada**), lo que aísla el efecto de la política de asignación. Se emplearon diez semillas ($s \in \{2025, \ldots, 2034\}$), de las cuales siete produjeron resultados válidos; las tres restantes se descartaron porque la totalidad de sus órdenes permaneció en estado *ready* sin asignación, atribuible a una interrupción del servicio OSRM. Los valores reportados corresponden al promedio de las siete réplicas válidas, generando $4 \times 7 \times 2 = 56$ corridas.

El desempeño se cuantifica mediante 21 indicadores agrupados en cinco dimensiones: calidad de servicio (CtD, RtP, RtD, cumplimiento SLA y exceso sobre el objetivo o *CTD Overage*), cobertura (% de pedidos no entregados), eficiencia operativa (pedidos por repartidor por hora, utilización y distancia por pedido), eficiencia de agrupamiento (tamaño promedio de agrupamiento) y costo (costo por pedido, derivado de la Ecuación 1). Para validar la significancia de las diferencias se aplica la prueba no paramétrica de Mann-Whitney U (Mann y Whitney, 1947) con corrección de Benjamini-Hochberg y correlación rank-biserial r como tamaño del efecto (Cohen, 1988), complementada con la prueba ómnibus de Kruskal-Wallis. Se eligió Mann-Whitney U porque la prueba de Shapiro-Wilk rechazó la normalidad de los KPIs y por su robustez ante valores atípicos.

4. Resultados y discusión

4.1. Calidad de servicio

La Tabla 2 presenta los indicadores de calidad de servicio promediados sobre las siete réplicas válidas. El *Click-to-Door* (CtD) es la métrica principal de calidad percibida por el cliente.

Tabla 2: Indicadores de calidad de servicio: promedio de 7 réplicas. Fuente: elaboración propia.

	Avg CtD (min)			P90 CtD (min)			SLA (%)		
Esc.	FCFS	RH	Δ%	FCFS	RH	Δ%	FCFS	RH	Δ%
S1	10.10	20.38	+101.8	13.10	31.51	+140.5	100.0	99.2	−0.8
S2	16.68	22.74	+36.3	32.73	35.46	+8.3	91.7	97.0	+5.8
S3	35.79	25.52	−28.7	117.19	39.94	−65.9	76.3	90.2	+18.2
S4	75.41	32.26	−57.2	228.01	52.27	−77.1	61.2	78.3	+27.9

En el escenario de baja saturación (S1), con oferta holgada de repartidores, FCFS logra tiempos menores que RH (10.10 vs 20.38 min), porque despacha cada pedido de inmediato al courier más cercano mientras que RH introduce la latencia del ciclo de optimización y la espera para formar agrupamientos. No obstante, ambas políticas se mantienen muy por debajo del objetivo SLA de 40 min. En S2 la brecha se reduce (+36.3 %) y, notablemente, el cumplimiento SLA se invierte a favor de RH (97.0 % vs 91.7 %): antes incluso de superar a FCFS en promedio, la coordinación de agrupamientos ya reduce los pedidos que exceden el umbral.

A partir de S3, RH supera decisivamente a FCFS: el CtD promedio baja un 28.7 % y el percentil 90 cae de 117.19 a 39.94 min (−65.9 %), comprimiendo la cola derecha de la distribución. En S4 la ventaja es máxima: el CtD promedio se reduce un 57.2 % y el P90 un 77.1 %; además, bajo FCFS un 11.5 % de los pedidos queda sin entregar al cierre, mientras que bajo RH se entrega la totalidad (0 %). La Figura 1 ilustra el colapso progresivo de FCFS en S3–S4 (cajas con alta dispersión y valores atípicos por encima de 300 min) frente a la distribución compacta de RH.

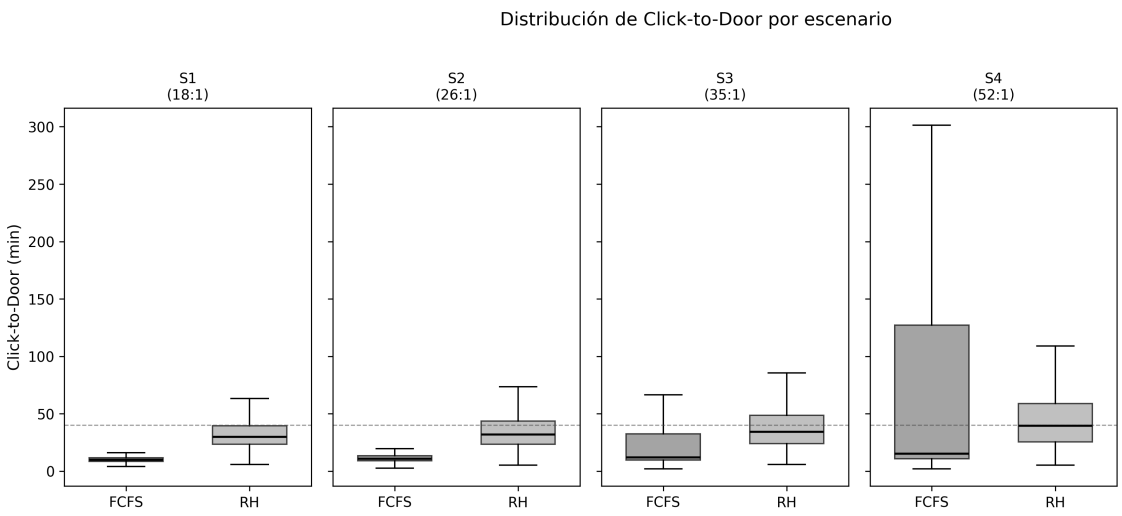


Figura 1: Distribución del *Click-to-Door* por escenario y política. La línea punteada indica el objetivo SLA de $\tau = 40$ min. Fuente: elaboración propia.

4.2. Eficiencia operativa y agrupamiento

La Tabla 3 resume la eficiencia operativa. El *throughput* (pedidos por repartidor por hora) bajo RH es ligeramente superior en S1–S3 y se amplía a $+17.7\,\%$ en S4, gracias al agrupamiento: al asignar varios pedidos por viaje, cada turno produce más entregas. La utilización del courier, en cambio, es *menor* bajo RH en S2–S4; esto no indica ociosidad sino mayor eficiencia kilométrica, pues los agrupamientos reducen la distancia por pedido hasta un 39.9 % en S4 (de 5.41 a 3.25 km), con el consiguiente ahorro de combustible y tiempo de conducción.

Tabla 3: Indicadores de eficiencia operativa: promedio de 7 réplicas. Fuente: elaboración propia.

	Ped./Rep./Hr			Utilización (%)			Dist./Pedido (km)		
Esc.	FCFS	RH	Δ%	FCFS	RH	Δ%	FCFS	RH	Δ%
S1	1.43	1.50	+4.9	18.0	20.9	+16.1	4.49	4.73	+5.3
S2	2.07	2.14	+3.4	27.3	26.9	−1.5	4.77	4.23	−11.3
S3	2.77	2.90	+4.7	38.4	32.7	−14.8	5.04	3.82	−24.2
S4	3.62	4.26	+17.7	53.0	40.7	−23.2	5.41	3.25	−39.9

Bajo FCFS cada courier recibe órdenes individuales (tamaño de agrupamiento igual a 1.0). Bajo RH, el tamaño promedio de agrupamiento crece monotónicamente con la saturación, de 1.77 en S1

a 3.07 en S4 (Tabla 4), reflejando la adaptación dinámica del algoritmo. La Figura 2 muestra que en S1 más de la mitad de los pedidos se despachan individualmente, mientras que en S4 la mayoría se agrupa en *bundles* de 3–4. El costo por pedido converge a $p_1 = \$10$ a medida que aumenta la saturación, pues el pago variable domina sobre el mínimo garantizado.

Tabla 4: Indicadores de agrupamiento y costo: promedio de 7 réplicas. Fuente: elaboración propia.

	Tamaño de agrup.			Costo/Pedido ($)		
Esc.	FCFS	RH	Δ%	FCFS	RH	Δ%
S1	1.00	1.77	+77.0	11.40	11.06	−3.0
S2	1.00	2.28	+128.0	10.01	10.07	+0.6
S3	1.00	2.67	+167.0	10.00	10.00	+0.0
S4	1.00	3.07	+207.0	10.00	10.00	+0.0

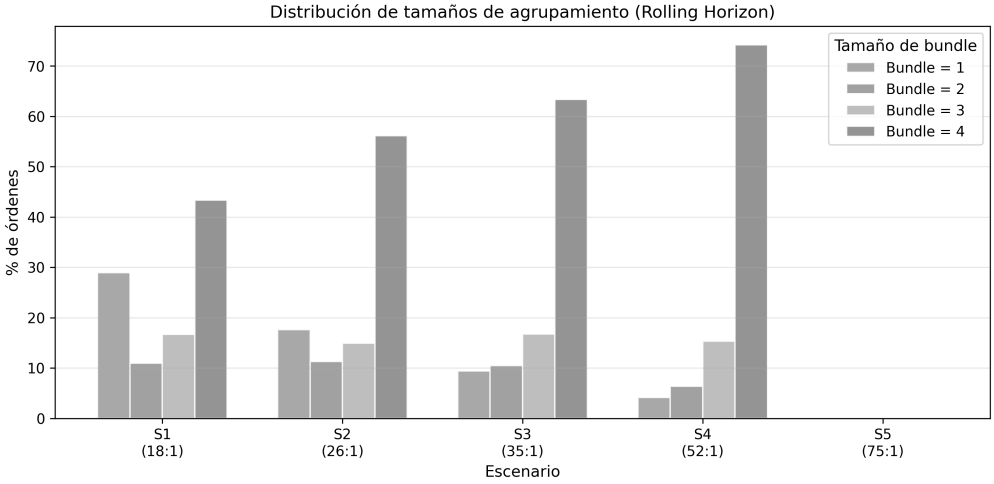


Figura 2: Distribución del tamaño de agrupamiento bajo RH por escenario. Fuente: elaboración propia.

4.3. Análisis estadístico

La Tabla 5 presenta la prueba de Mann-Whitney U para el CtD. Las 28 pruebas individuales (4 escenarios $\times$ 7 semillas) resultaron significativas tras la corrección de Benjamini-Hochberg. El tamaño del efecto disminuye de S1 a S4, lo que requiere interpretación cuidadosa: en S1–S2 el

efecto grande favorece a FCFS en la comparación ordinal; en S4, el efecto pequeño ($\bar{r} = 0.144$) no refleja ausencia de diferencia, sino la alta variabilidad de FCFS (distribución bimodal con cola de horas), pese a que RH reduce el CtD promedio un 57.2 %. La prueba de Kruskal-Wallis confirma que el efecto de la política varía significativamente entre escenarios ($H = 782.78$, $p < 0.001$), justificando el análisis por regímenes de saturación.

Tabla 5: Prueba de Mann-Whitney U para el *Click-to-Door*: 7 semillas ($\bar{r} \pm \sigma_r$). Fuente: elaboración propia.

Esc.	$\bar{x}_{\text{FCFS}}$	$\bar{x}_{\text{RH}}$	p	$\bar{r} \pm \sigma_r$	Efecto
S1	10.10	20.38	< 0.001	0.911 ± 0.018	Grande
S2	16.68	22.74	< 0.001	0.687 ± 0.045	Grande
S3	35.79	25.52	< 0.001	0.406 ± 0.046	Mediano
S4	75.41	32.26	< 0.001	0.144 ± 0.030	Pequeño

4.4. Discusión

Los resultados revelan dos regímenes con una zona de transición identificable (Figura 3). En el **régimen de baja saturación (S1–S2)**, la política reactiva FCFS logra menores tiempos promedio porque despacha cada pedido sin latencia de agrupamiento; sin embargo, ya en S2 aparece una señal temprana de la ventaja de RH (mayor cumplimiento SLA y reducción del *CTD Overage* superior al 96 %). En el **régimen de saturación media–alta (S3–S4)**, RH supera a FCFS en todas las métricas de calidad, con reducciones del CtD del 28.7 % al 57.2 % y la eliminación total de pedidos no entregados en S4. Las curvas de CtD se cruzan entre $r = 26$ y $r = 35$, marcando el punto donde la anticipación comienza a dominar.

La Figura 4 muestra el compromiso entre utilización y costo por pedido: RH logra menor utilización con *throughput* equivalente o superior, lo que confirma su mayor eficiencia kilométrica. En conjunto, estos hallazgos superan el rango de mejora de 10–25 % que Reyes y cols. (2018) reportan al pasar de asignación reactiva a horizonte rodante en ciudades estadounidenses, lo que sugiere que la topología vial de La Paz —de menor conectividad y mayor variabilidad de distancias— amplifica la ventaja del agrupamiento. Este resultado es coherente con la advertencia de Boyacı y cols.

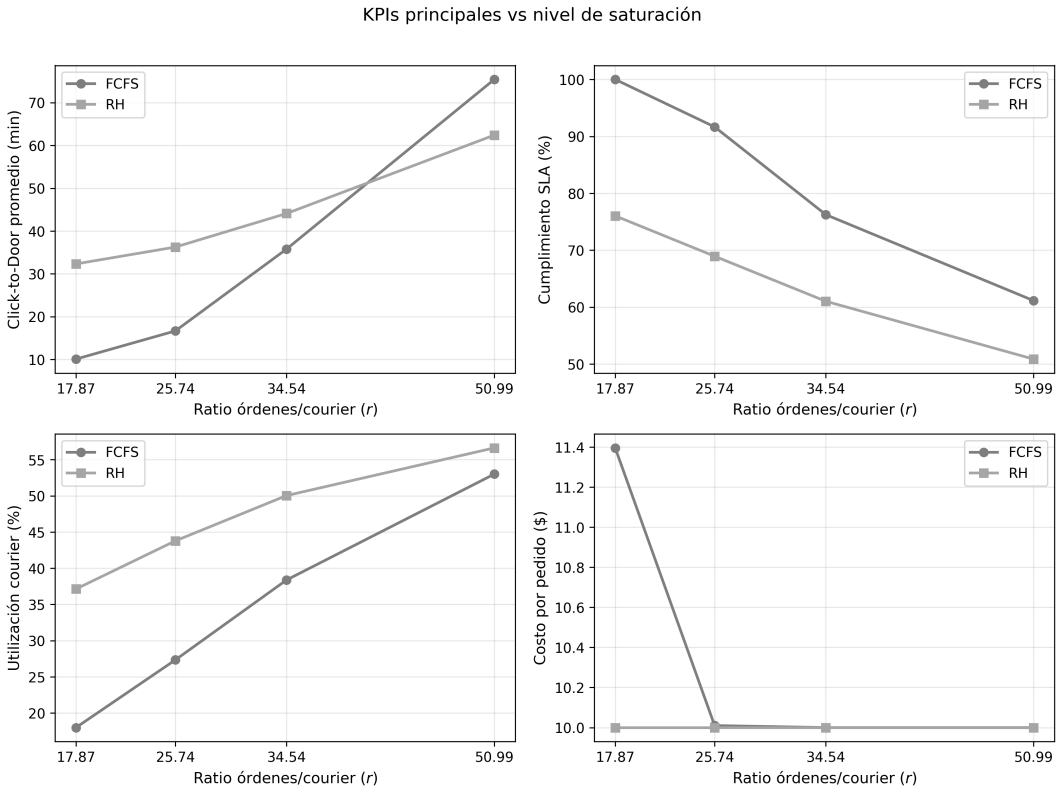


Figura 3: Evolución de los KPIs principales en función de la saturación. El cruce de las curvas de CtD entre los ratios 26 y 35 marca la transición de régimen. Fuente: elaboración propia.

(2021) y Figliozzi (2007) sobre la distorsión de las aproximaciones lineales en redes reales.

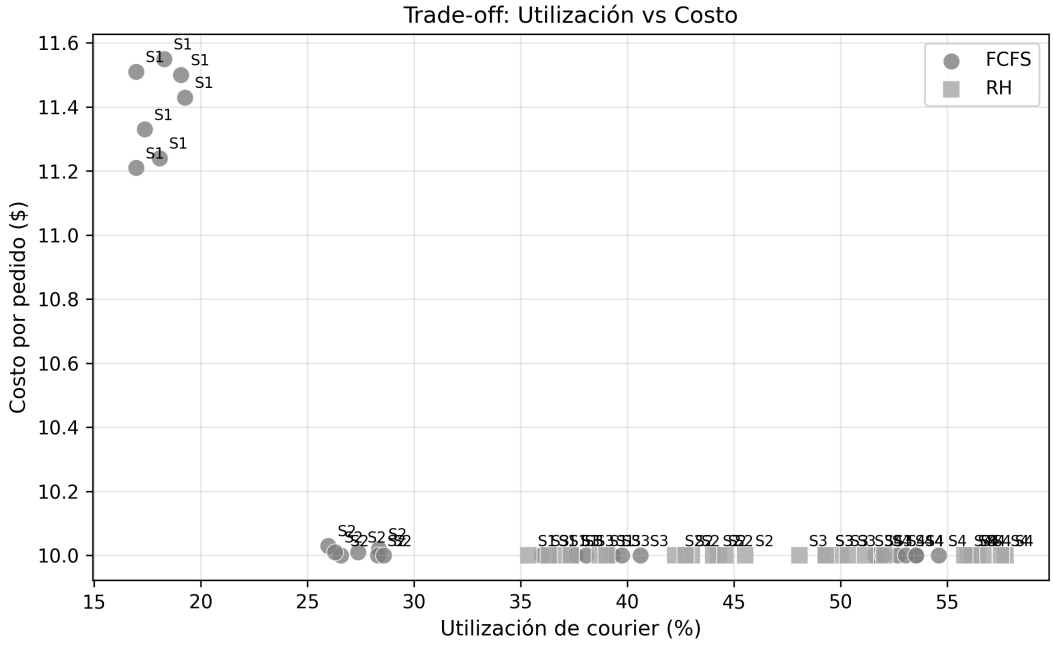


Figura 4: Compromiso entre utilización del repartidor y costo por pedido. Fuente: elaboración propia.

Los resultados deben interpretarse considerando las limitaciones del modelo: la demanda es sintética (Poisson) y puede no capturar la variabilidad de una operación comercial; los tiempos de preparación y de servicio son homogéneos; la red vial se asume estática (sin congestión dinámica); y tres de las diez semillas no generaron resultados válidos por una interrupción del servicio OSRM.

5. Conclusiones

Se desarrolló y evaluó un entorno de simulación reproducible para el MDRP que integra tiempos de viaje reales sobre la red vial de La Paz, B.C.S., utilizando exclusivamente software de código abierto (OSRM, OpenStreetMap, Python y Docker). El objetivo general se cumplió: se ejecutaron 56 corridas válidas sobre la red real y se cuantificaron las diferencias entre las políticas FCFS y *Rolling Horizon* con pruebas estadísticas formales.

La hipótesis se verifica de forma **condicional al régimen de saturación**. Con flota holgada (S1–S2), la política reactiva es más rápida en promedio, aunque la anticipatoria ya mejora el cum-

plimiento SLA. A partir de la saturación media (S3), RH supera a FCFS en todas las métricas de calidad de servicio, y en alta saturación (S4) reduce el CtD promedio un 57.2 %, su percentil 90 un 77.1 % y elimina los pedidos no entregados. El *throughput* bajo RH es consistentemente superior y la distancia por pedido se reduce hasta un 39.9 %.

Las contribuciones principales son: (1) un entorno de simulación reproducible y abierto aplicado por primera vez a una ciudad latinoamericana de escala media; (2) la evidencia empírica de un punto de cruce ($r \approx 26$–35) a partir del cual la anticipación supera a la asignación reactiva, útil como guía práctica para operadores; y (3) la constatación de que los beneficios del horizonte rodante no solo se mantienen sino que se amplifican sobre una topología vial real y hostil, superando las mejoras reportadas en la literatura para redes de cuadrícula. Al prescindir de APIs comerciales, el enfoque ofrece una alternativa de soberanía tecnológica que reduce las barreras de entrada para las PyMES locales (Muñoz-Villamizar, Solano-Charris, Reyes-Rubiano, y Faulin, 2021).

Como líneas de trabajo futuro se plantea: diagnosticar la condición de borde que invalidó tres semillas; sustituir la demanda sintética por datos operacionales reales; incorporar perfiles de congestión dinámica en OSRM; y localizar con mayor precisión el punto de cruce explorando valores intermedios de r.

Referencias

Boeing, G. (2021). Street network models and indicators for every urban area in the world. *Geographical Analysis*, *53*(3), 482–508. (Ver también su trabajo en OSMnx para validación topológica) doi: 10.1111/gean.12281

Boyacı, B., Dang, T. H., y Letchford, A. N. (2021). Vehicle routing on road networks: How good is euclidean approximation? *Computers & Operations Research*, *129*, 105197. doi: 10.1016/j.cor.2020.105197

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Dantzig, G. B., y Ramser, J. H. (1959). The truck dispatching problem. *Management Science*, *6*(1), 80-91.

Figliozzi, M. A. (2007). Analysis of the efficiency of urban commercial vehicle tours: Data collection, methodology, and policy implications. *Transportation Research Part B: Methodological*, *41*(9), 1014–1032. doi: 10.1016/j.trb.2007.04.006

Geisberger, R., Sanders, P., Schultes, D., y Delling, D. (2008). Contraction hierarchies: Faster and simpler hierarchical routing in road networks. En *Proceedings of the 7th international workshop on experimental algorithms (wea 2008)* (Vol. 5038, pp. 319–333). Berlin, Heidelberg: Springer. doi: 10.1007/978-3-540-68552-4_24

Haklay, M. (2010). How good is volunteered geographical information? a comparative study of openstreetmap and ordnance survey datasets. *Environment and Planning B: Planning and Design*, *37*(4), 682–703. doi: 10.1068/b35097

Jazemi, R., Alidadiani, E., Ahn, K., y Jang, J. (2023). A review of literature on vehicle routing problems of last-mile delivery in urban areas. *Applied Sciences*, *13*(2413015).

Kuhn, H. W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, *2*(1–2), 83–97. doi: 10.1002/nav.3800020109

Laporte, G. (2009). Fifty years of vehicle routing. *Transportation Science*, *43*(4), 408–416. doi: 10.1287/trsc.1090.0301

Larsen, J. (2000). The dynamic vehicle routing problem: Survey of classifications. *Computers & Operations Research*, *27*(10), 103–122. doi: 10.1016/S0305-0548(99)00100-X

Mann, H. B., y Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, *18*(1), 50–60. doi: 10.1214/aoms/1177730491

Merkel, D. (2014). Docker: Lightweight linux containers for consistent development and deployment. *Linux Journal*, *2014*(239), 2. Descargado de `http://www.linuxjournal.com/content/docker-lightweight-linux-containers-consistent-development-and-deployment`

Muñoz-Villamizar, A., Solano-Charris, E. L., Reyes-Rubiano, L., y Faulin, J. (2021). Measuring disruptions in last-mile delivery operations. *Logistics*, *5*(1). doi: 10.3390/logistics5010017

Pereira, R. H. M., Saraiva, M., Herszenhut, D., Braga, C. K., y Conway, M. W. (2021). r5r: Rapid realistic routing on multimodal transport networks with R5 in R. *Findings*. Descargado de `https://findingspress.org/article/21262-r5r-rapid-realistic-routing`

-on-multimodal-transport-networks-with-r5-in-r doi: 10.32866/001c.21262

Pillac, V., Gendreau, M., Guéret, C., y Medaglia, A. L. (2013). A review of dynamic vehicle routing problems. *European Journal of Operational Research*, *225*(1), 1–11. doi: 10.1016/j.ejor.2012.08.015

Reyes, D., Erera, A., Savelsbergh, M., Sahasrabudhe, S., y O'Neil, R. (2018, March). The meal delivery routing problem. *Optimization Online*. Descargado de http://www.optimization-online.org/DB_FILE/2018/03/6512.pdf

Ross, S. M. (2014). *Introduction to probability models* (11th ed.). Amsterdam: Academic Press.

Wu, L., Wen, H., Hu, H., Wang, Y., Li, Y., Wang, J., ... Xu, M. (2023). Lade: The first comprehensive last-mile delivery dataset from industry. En *Proceedings of the 32nd acm international conference on information and knowledge management (cikm '23)* (p. 2619–2628). doi: 10.1145/3583780.3614820